

دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

گزارش تمرین سوم درس داده‌کاوی محاسباتی

مبانی محاسباتی رگرسیون (پایداری و مقیاس پذیری)

نگارش
زهرا براتی

استاد درس
دکتر مهدی قطعی

تدریسیار
آقای بهنام یوسفی‌مهر

۱۴۰۴ آذر

چکیده

در این پژوهش، سه رویکرد مختلف برای حل مسائل رگرسیون خطی و غیرخطی بررسی شده است. در ابتدا، با استفاده از یک مجموعه داده کوچک، عملکرد روش‌های مستقیم شامل معادلات نرمال و SVD ارزیابی شد. نتایج نشان داد که معادلات نرمال در حضور هم‌خطی دچار ناپایداری عددی می‌شود، در حالی که SVD با کنترل مقادیر منفرد کوچک راه حلی پایدار و قابل اعتماد ارائه می‌کند. در ادامه و با استفاده از داده بزرگ‌تر Auto MPG، رفتار الگوریتم‌های تکراری گرادیان کاهشی دسته‌ای و تصادفی مقایسه شد. مشاهده شد که هرچند BGD مسیر همگرایی یکنواخت‌تری دارد، هزینه محاسباتی آن برای داده‌های بزرگ بالا است و SGD با وجود نوسان، کاراتر و سریع‌تر به ناحیه بهینه می‌رسد. در بخش پایانی، یک مدل رگرسیون چندجمله‌ای درجه دو برای تقریب رابطه Horsepower و MPG ساخته شد. منحنی به دست آمده نشان داد که مدل غیرخطی به دلیل توانایی در ثبت تغییرات شبیب، توصیف دقیق‌تری نسبت به مدل خطی ارائه می‌دهد. در مجموع، تحلیل‌ها نشان می‌دهد که انتخاب روش مناسب در رگرسیون به اندازه داده، ساختار ویژگی‌ها و الزامات پایداری عددی بستگی دارد.

واژه‌های کلیدی:

رگرسیون خطی، رگرسیون چندجمله‌ای، معادلات نرمال، تجزیه مقادیر منفرد، گرادیان کاهشی دسته‌ای، گرادیان کاهشی تصادفی

صفحه	فهرست مطالب
۱	چکیده
۲	فصل اول: مقدمه
۳	فصل دوم: مبانی محاسباتی (داده‌های کوچک)
۴	۱-۲- روش مستقیم (Equations Normal)
۵	۲-۲- روش تکراری (Batch Gradient Descent)
۶	۳-۲- روش مستقیم پایدار (SVD)
۷	۴-۲- تحلیل پایداری محاسباتی
۸	۴-۴-۱- مقایسه مقادیر θ در سه روش پیشین
۹	۴-۴-۲- ساخت ماتریس با هم خطی شدید
۱۰	۴-۴-۳- تحلیل
۱۱	فصل سوم: تحلیل مقیاس پذیری محاسباتی (داده‌های بزرگ)
۱۲	۱-۳- بارگذاری داده‌ها و آماده‌سازی ماتریس‌ها
۱۳	۲-۳- مقایسه محاسباتی SGD در مقابل BGD
۱۴	۳-۳- تحلیل محاسباتی
۱۵	فصل چهارم: کاربرد (رگرسیون غیرخطی)
۱۶	فصل پنجم: جمع‌بندی و نتیجه‌گیری
۱۷	منابع و مراجع
۱۸	پیوست‌ها

فصل اول

مقدمه

مقدمه

رگرسیون یکی از پایه‌ای ترین ابزارها برای تحلیل رابطه بین متغیرهای است و در بیشتر کاربردهای یادگیری ماشین نقش مهمی دارد. با این حال، روش‌هایی که برای حل رگرسیون استفاده می‌کنیم بسته به اندازه داده، نوع ویژگی‌ها و محدودیت‌های محاسباتی می‌توانند رفتار کاملاً متفاوتی داشته باشند. در این پژوهه تلاش شده است که این تفاوت‌ها به صورت مرحله‌به‌مرحله بررسی شود.

در بخش اول، با یک مجموعه‌داده کوچک کار شد تا عملکرد روش‌های مستقیم مثل معادلات نرمال و تجزیه SVD بررسی شود و مشخص شود که این روش‌ها در حضور هم‌خطی چطور دچار ناپایداری عددی می‌شوند. در بخش دوم، داده بزرگ‌تری انتخاب شد تا رفتار الگوریتم‌های گرادیان کاهشی دسته‌ای و تصادفی از نظر سرعت و مقیاس‌پذیری مقایسه شود. در نهایت، در بخش سوم یک مدل چندجمله‌ای درجه دو ساخته شد تا نشان داده شود که استفاده از مدل‌های غیرخطی چگونه می‌تواند الگوهای واقعی داده را بهتر از مدل خطی ساده ثبت کند. هدف اصلی این گزارش این است که نشان دهد انتخاب روش مناسب برای رگرسیون کاملاً به شرایط مسئله و ویژگی‌های داده بستگی دارد.

فصل دوم

مبانی محاسباتی (داده‌های کوچک)

مبانی محاسباتی (داده‌های کوچک)

در این بخش،

۱-۲- روش مستقیم (Equations Normal)

معادلات نرمال^۱ راه حل تحلیلی و مستقیم برای مسئله کمترین مربعات خطی است. برای یافتن بردار ضرایب θ که خطای $\|A\theta - y\|^2$ را کمینه می‌کند، به جای بهینه‌سازی تکراری، می‌توان مستقیماً سیستم معادلات خطی $A^T A\theta = A^T y$ را حل کرد.

راه حل به صورت $\theta = (A^T A)^{-1} A^T y$ است. این روش برای d (تعداد ویژگی‌ها) کم، بسیار سریع است، اما دو مشکل محاسباتی اساسی دارد:

۱. هزینه معکوس کردن ماتریس $A^T A$ از مرتبه $O(d^3)$ است که برای d بزرگ بسیار سنگین است.

۲. اگر ویژگی‌ها هم خطی داشته باشند، ماتریس $A^T A$ تکین^۲ یا بدحالت^۳ شده و معکوس آن از نظر عددی ناپایدار یا غیرممکن می‌شود.

مقدار θ به دست آمده از این روش برابر $\begin{bmatrix} -1.04137931 \\ 2.03103448 \end{bmatrix}$ است. این بردار نشان می‌دهد که مدل خطی به شکل تقریباً $x = -1.0414 + 2.0310$ را توصیف می‌کند.

۲-۲- روش تکراری (Batch Gradient Descent)

گرادیان کاهشی دسته‌ای^۴ یک روش بهینه‌سازی تکراری است که با شروع از یک θ اولیه، به صورت گام‌به‌گام به سمت کمینه تابع هزینه $J(\theta)$ حرکت می‌کند.

¹ Equations Normal

² Singular

³ ill-conditioned

⁴ Batch Gradient Descent (BGD)

در هر گام، گرادیان (مشتق) تابع هزینه محاسبه شده و θ در خلاف جهت آن حرکت می‌کند.

در این روش «دسته‌ای^۵» به این معناست که برای محاسبه گرادیان در هر گام، از تمام n نمونه موجود

$$\text{در مجموعه داده استفاده می‌شود: } \nabla J(\theta) = \frac{1}{m} A^T (A\theta - y)$$

همچنین رابطه بهروزرسانی θ در الگوریتم گرادیان کاهشی دسته‌ای برابر است با:

$$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla J(\theta^{(k)})$$

$$J(\theta_{BGD}) = 0.01873 \quad \begin{bmatrix} [-0.55217831] \\ [1.9146829] \end{bmatrix} \quad \theta \text{ برابر} \quad n_{\text{iterations}} = 1000$$

دست آمد.

این نتیجه نشان می‌دهد که الگوریتم گرادیان کاهشی با پارامترهای انتخاب شده هنوز به مقدار بهین θ (که در بخش قبل محاسبه شد) نرسیده است. با افزایش تعداد تکرارها یا تنظیم نرخ یادگیری می‌توان مقدار θ را به جواب دقیق‌تری نزدیک کرد.

۳-۲- روش مستقیم پایدار (SVD)

روشی بسیار پایدارتر برای حل مستقیم رگرسیون، استفاده از شبهمعکوس مور-پنروز (A^+) است. بهترین و استانداردترین راه محاسباتی برای یافتن A^+ ، استفاده از تجزیه مقادیر منفرد^۶ است.

اگر $A = U\Sigma V^T$ باشد، آنگاه: $A^+ = V\Sigma^+ U^T$. این روش حتی اگر ماتریس $A^T A$ تکین باشد (یعنی هم خطی کامل وجود داشته باشد)، یک راه حل منحصر به فرد و بهینه (با کمترین نرم) ارائه می‌دهد و از نظر عددی بسیار پایدار است.

$$\text{در نتیجه محاسبات برای این روش } \theta \text{ برابر} \begin{bmatrix} [-1.04137931] \\ [2.03103448] \end{bmatrix} \text{ که دقیقاً با } \theta \text{ حاصل از روش معادلات نرمال برابر است.}$$

⁵ Batch

⁶ Singular Value Decomposition (SVD)

۴-۲- تحلیل پایداری محاسباتی

در این بخش به تحلیل پایداری محاسباتی می‌پردازیم.

۱-۴-۲- مقایسه مقادیر θ در سه روش پیشین

در جدول زیر مقادیر محاسبه شده قابل مشاهده است.

θ_1	θ_0	روش
2.03103448	-1.04137931	Equations Normal
1.9146829	-0.55217831	BGD
2.03103448	-1.04137931	SVD

همانطور که می‌بینیم، θ به دست آمده از SVD دقیقاً با نتیجه معادلات نرمال همسان است، در حالی که گرادیان کاهشی به دلیل تعداد تکرار محدود مقادیری متفاوت ارائه می‌دهد. با افزایش تعداد تکرارها یا تنظیم نرخ یادگیری می‌توان نتیجه BGD را به θ دقیق نزدیک‌تر کرد.

۲-۴-۲- ساخت ماتریس با هم‌خطی شدید

پس از ساخت ماتریس جدید با روابط داده شده

```
01 noise = np.random.rand(m, 1) * 0.0001
02 A_collinear = np.hstack((A, A[:, [1]] + noise))
```

و حل مجدد مسئله با روش معادلات نرمال و تجزیه مقادیر منفرد، نتایج زیر حاصل شد:

θ_2	θ_1	θ_0	روش
-3.43623267e+03	3.43827452e+03	-8.53782625e-01	Equations Normal
-3.43622113e+03	3.43826298e+03	-8.53775599e-01	SVD

لازم به ذکر است با قرار دادن $noise = 0$ محاسبات حاصل از روش معادلات نرمال با خطای «Singular matrix» مواجه شد. در حالی که روش تجزیه مقادیر منفرد بدون خطا اجرا شد.

۳-۴-۲ - تحلیل

وقتی در حضور هم خطی شدید، ماتریس $A^T A$ تقریباً تکین و از نظر عددی بدهالت می‌شود. این وضعیت باعث می‌شود روش معادلات نرمال هنگام معکوس‌گیری این ماتریس، به مقادیر ناپایدار و ضرایب بسیار بزرگ یا حتی شکست محاسباتی منجر شود. مقالات موجود نیز همین پدیده را گزارش می‌کنند و نشان می‌دهند که وابستگی خطی میان ویژگی‌ها خطاهای گردشی (round-off) را تقویت کرده و واریانس ضرایب مدل را به شدت افزایش می‌دهد.

در مقابل، روش SVD از معکوس‌گیری مستقیم $A^T A$ پرهیز می‌کند و به جای آن ماتریس A را به صورت $A = U\Sigma V^T$ تجزیه می‌کند. وقتی هم خطی وجود داشته باشد، یکی از مقادیر منفرد σ_i بسیار کوچک می‌شود؛ SVD این مقادیر کوچک را کنترل کرده و در شبهمعکوس آن‌ها را به شکلی پایدار مدیریت می‌کند. به همین دلیل مقالات تأکید می‌کنند که SVD خطاهای عددی را تقویت نمی‌کند و حتی در شرایط هم خطی یا رتبه ناکامل، پایدارترین تخمین ممکن (کمترین نرم) را ارائه می‌دهد.

به صورت خلاصه، معادلات نرمال به دلیل وابستگی به $(A^T A)^{-1}$ در برابر هم خطی حساس و ناپایدار است، در حالی که SVD با کنترل مقادیر منفرد کوچک، یک راه حل پایدار و مقاوم در برابر نویز و خطای محاسباتی فراهم می‌کند.

فصل سوم

تحلیل مقیاس پذیری محاسباتی (داده‌های بزرگ)

تحلیل مقیاس پذیری محاسباتی (داده‌های بزرگ)

در این بخش، کارایی روش‌های مبتنی بر گرادیان در مقیاس بزرگ بررسی می‌شود. برخلاف بخش اول که مسئله تنها یک ویژگی و چهار نمونه داشت، داده Auto MPG شامل چند صد نمونه است و از این جهت می‌توان تفاوت رفتاری روش‌های تکراری را بهتر مشاهده کرد.

در ادامه، داده Auto MPG بارگذاری و پاکسازی می‌شود، ماتریس طراحی برای مدل خطی ساخته و نرمال‌سازی و سپس هر یک از دو الگوریتم BGD و SGD به‌طور جداگانه اجرا و مسیر همگرایی آن‌ها تحلیل می‌شود.

۱-۳- بارگذاری داده‌ها و آماده‌سازی ماتریس‌ها

در این مرحله داده Auto MPG از مخزن UCI بارگذاری و مقادیر گمشده ستون Horsepower حذف و برچسب MPG و ویژگی ورودی Horsepower انتخاب شد. برای بهبود همگرایی روش‌های مبتنی بر گرادیان، ستون Horsepower به‌صورت استاندارد نرمال‌سازی شده و سپس ماتریس طراحی A مطابق $y = \theta_0 + \theta_1 \times \text{Horsepower}$ ساخته شد که ستون ثابت و یک ستون ویژگی مدل Horsepower نرمال‌شده است. داده آماده‌شده در مراحل بعد برای اجرای BGD و SGD مورد استفاده قرار می‌گیرد.



۲-۳- مقایسه محاسباتی BGD در مقابل SGD

در این مرحله پس از پیاده‌سازی BGD و SGD، نتایج زیر حاصل شد:

Last J	θ_1	θ_0	روش
11.971832015876284	-6.06761045	23.44490618	BGD
12.236104231855803	-6.68718906	23.82669705	SGD

همچنین نمودار همگرایی بر حسب تکرار نشان می‌دهد که هر دو روش در تکرارهای ابتدایی کاهش تند دارند و سریعاً به ناحیه کمینه می‌رسند. در شکل بزرگ مقیاس، منحنی‌های دو روش تقریباً روی یکدیگر قرار می‌گیرند، اما در بزرگ‌نمایی تکرارهای نخست، می‌توان مشاهده کرد که BGD مسیر یکنواخت‌تری

دارد، در حالی که SGD به دلیل استفاده از نمونه‌های تصادفی دارای نوسان‌های کوچک است. با این وجود، هر دو روش به مقدار تقریباً مشابهی از $J(\theta)$ همگرا می‌شوند که نشان‌دهنده سادگی مدل و اثر نرمال‌سازی ویژگی است.



۳-۳- تحلیل محاسباتی

در مسائل یادگیری ماشین مقیاس بزرگ، استفاده از روش گرادیان کاوشی دسته‌ای به دلیل هزینه

محاسباتی زیاد هر تکرار کارآمد نیست؛ زیرا در هر گام لازم است گرادیان بر روی کل داده‌ها محاسبه شود که برای مجموعه داده‌های بزرگ بسیار سنگین است. در مقابل، روش گرادیان کاهشی تصادفی در هر تکرار تنها از یک نمونه داده‌ها استفاده می‌کند. اگرچه مسیر همگرایی در SGD نویزی‌تر از BGD است، اما به دلیل تعداد بسیار بیشتر به روزرسانی‌ها در زمان ثابت، در عمل بسیار سریع‌تر به ناحیه‌ی کمینه تابع هزینه نزدیک می‌شود. بنابراین، در محیط‌های محاسباتی بزرگ و کاربردهای عملی یادگیری ماشین، روش‌های مبتنی بر SGD بر BGD به دلیل هزینه‌ی سنگین محاسباتی ارجحیت دارد.

فصل چهارم

کاربرد (رگرسیون غیرخطی)

کاربرد (رگرسیون غیرخطی)


در این بخش، با استفاده از ویژگی Horsepower از مجموعه داده Auto MPG، یک مدل رگرسیون چندجمله‌ای درجه دو به فرم $y = \theta_0 + \theta_1x + \theta_2x^2$ ساخته شد. برای بهبود همگرایی، ستون‌های x و x^2 به صورت جداگانه نرمال‌سازی شدند و ماتریس A_{poly} شامل سه ستون $[1, x_{\text{norm}}, x_{\text{norm}}^{(2)}]$ تشکیل شد.

پس از اجرای روش SGD بر روی ماتریس جدید، نتایج زیر حاصل شد:

Last J	θ_2	θ_1	θ_0	روش
10.719091833697766	5.55257232	-12.48909616	23.7286363	SGD

این مقادیر نشان می‌دهد که مدل یاد گرفته است که چگونه رابطه غیرخطی بین توان موتور (Horsepower) و مصرف سوخت (MPG) را تقریب بزند. ضریب منفی θ_1 نشان‌دهنده کاهش اولیه MPG با افزایش Horsepower است، در حالی که ضریب مثبت θ_2 نقش انحنای مدل را تعیین می‌کند و باعث می‌شود مدل بتواند روند ملایم‌تر و خمیده قسمت‌های انتهایی داده‌ها را دنبال کند.

در نهایت با رسم منحنی رگرسیون به دست آمده (مدل چندجمله‌ای) روی نمودار پراکندگی داده‌ها، مشاهده شد نتایج به دست آمده انطباق مناسبی با داده‌های واقعی دارند.



فصل پنجم

جمع‌بندی و نتیجه‌گیری

جمع‌بندی و نتیجه‌گیری

در این پروژه، سه رویکرد مختلف برای برازش مدل‌های خطی و غیرخطی بر روی داده‌ها بررسی شد. در بخش نخست، تحلیل روی داده‌های کوچک نشان داد که روش‌های مستقیم مانند معادلات نرمال در مسائل هم‌خطی حساسیت بالایی دارند و ممکن است به پاسخ‌های ناپایدار ختم شوند، در حالی که روش SVD با کنترل مقادیر منفرد کوچک، راه حلی پایدارتر ارائه می‌کند. این تفاوت در شرایطی آشکارتر شد که ستون‌های ماتریس طراحی وابستگی شدید داشتند و معادلات نرمال دچار مشکل شدند.

در بخش دوم، با استفاده از داده بزرگ‌تر MPG Auto، رفتار الگوریتم‌های تکراری بررسی شد. نتایج نشان داد که گرادیان کاهشی دسته‌ای گرچه مسیری یکنواخت و بدون نوسان دارد، اما از نظر محاسباتی برای داده‌های بزرگ ناکارآمد است؛ زیرا هر تکرار مستلزم پردازش کل مجموعه داده است. در مقابل، روش گرادیان کاهشی تصادفی با وجود نوسان در مسیر همگرایی، به‌طور قابل توجهی از نظر زمانی مقرن‌به‌صرفه‌تر است و در عمل با تعداد زیادی به‌روزرسانی سبک، سریع‌تر به ناحیه کمینه نزدیک می‌شود. این رفتار، دلیل اصلی استفاده گسترده از روش‌های مبتنی بر SGD در کاربردهای یادگیری ماشین مقیاس‌بزرگ است.

در بخش سوم نیز یک مدل چندجمله‌ای درجه دو بر اساس ویژگی Horsepower ساخته شد. منحنی برازش‌شده نشان داد که افزودن جمله درجه دو موجب افزایش انعطاف مدل و بهبود تطابق آن با روند واقعی داده‌ها می‌شود.

در مجموع، نتایج نشان می‌دهد که انتخاب روش مناسب برای حل مسئله رگرسیون، به اندازه داده‌ها، ساختار ویژگی‌ها و الزامات پایداری عددی بستگی دارد. روش‌های مستقیم برای مسائل کوچک مناسب‌اند، روش‌های تجزیه‌ای مانند SVD در حضور هم‌خطی برتری دارند، و برای داده‌های بزرگ، الگوریتم‌های گرادیان تصادفی کارآمدترین انتخاب هستند. همچنین افزودن پیچیدگی کنترل شده به مدل (مانند درجه دوم) می‌تواند برازش بهتری نسبت به مدل خطی فراهم کند، بدون آن که هزینه محاسباتی چشمگیری تحمیل کند.

منابع و مراجع

- [1] R. F. G.V. Haines, "Modeling by singular value decomposition and the elimination of statistically insignificant coefficients," *Computers & Geosciences*, pp. 19-28, 2013.

<https://numpy.org>

پیوست‌ها

لینک گیت‌هاب پروژه:

<https://github.com/ZahraBarati99/Computational-Fundamentals-of-Regression-Stability-and-Scalability>

